Relatório de Análise Exploratória de Dados — EDA01 e EDA02

Dataset IoT-based Dataset of a Tomato Cultivation Under Different Irrigation Regimes

Material de apoio para apresentação — síntese das análises realizadas e interpretação dos resultados.

1. Objetivo das análises

As EDA01 e EDA02 tiveram como objetivo transformar o dataset bruto em uma visão utilizável para o projeto de irrigação autônoma. A EDA01 caracteriza a estrutura, qualidade, temporalidade e distribuição geral dos dados. A EDA02 parte dessa caracterização e concentra-se no ano de 2025, integrando variáveis ambientais, de solo, irrigação e volume de água para investigar a dinâmica hídrica da planta e a viabilidade de um futuro modelo de Inteligência Computacional.

A pergunta de projeto que orienta a análise é: como manter a planta dentro de uma faixa adequada de disponibilidade hídrica, acionando a irrigação quando necessário e evitando tanto déficit quanto excesso de água?

2. EDA01 — Caracterização do dataset

A primeira análise percorreu os arquivos organizados por ano (2023, 2024 e 2025). Foram identificados 21 arquivos CSV, contendo sensores ambientais, sensores de solo, controle de válvula, medição de água e indicadores de desenvolvimento da cultura.

A estrutura mostra uma evolução do experimento: 2023 possui dados ambientais, de solo, válvula e medidor de água; 2024 acrescenta pressão e potencial hídrico; e 2025 apresenta a cadeia mais rica para o projeto, incluindo ambiente, solo, válvula, volume de água, temperatura foliar, caule e fruto.

3. EDA01 — Dimensão e organização dos dados

O conjunto contém arquivos de tamanhos bastante diferentes. Entre os maiores estão leaf_temperature2025 (261.013 registros), pressure2025 (221.473), fruit2025 (201.899), soil2025 (193.066), water_meter2025 (143.470) e stem2025 (121.987).

Os arquivos de solo são particularmente importantes porque fornecem, por linha de cultivo, umidade, temperatura e condutividade elétrica. Os arquivos de válvula indicam o estado do atuador, enquanto os medidores de água registram current_volume. Os arquivos environmental registram CO2, pressão, temperatura e umidade do ar.

4. EDA01 — Variáveis principais

Principais grupos de variáveis encontrados:

- Ambiente: co2, pressure, temperature, humidity.
- Solo: electrical_conductivity, humidity, temperature.
- Irrigação: valve_state e current_volume.
- Estado da planta: leaf_temperature, stem_size e fruit_size.
- Indicadores de desenvolvimento: GDD e variáveis derivadas de temperatura.
- Identificação: line e generated_by.
- Tempo: ts_generation.

Para a finalidade do projeto, a variável central escolhida para a EDA02 foi a umidade do solo, posteriormente padronizada como soil_moisture.

5. EDA01 — Qualidade e valores ausentes

A EDA01 verificou valores ausentes por arquivo. Muitos arquivos não possuem ausências; alguns apresentam lacunas específicas. Exemplos: water_meter2023 possui 1 ausência em current_volume; water_valve2023 possui 431 ausências em valve_state, water_temperature e ambient_temperature; environmental2024 possui 3.506 ausências de pressure e 2 de humidity; soil2024 possui 296 de humidity e 19 em electrical_conductivity e temperature; leaf_temperature2025 possui 2.494 ausências; pressure2025 possui 620.

A conclusão não é simplesmente “apagar os dados ausentes”. As ausências devem ser tratadas conforme a função da variável e a etapa de modelagem, preservando a informação temporal quando possível.

6. EDA01 — Valores suspeitos

Algumas distribuições apresentaram valores que merecem investigação antes da modelagem. Em soil2024, por exemplo, humidity chega a 655,35 e electrical_conductivity a 65.535, sugerindo possível codificação/escala ou erro de aquisição. Em pressure2024 e pressure2025 aparecem muitos zeros. Em leaf_temperature2025 há mínimo igual a 0 °C.

Esses valores não foram simplesmente classificados como “erro” sem confirmação. A abordagem recomendada é marcá-los como suspeitos, verificar documentação/semântica do sensor e comparar os eventos com outras variáveis.

7. EDA01 — Tempo

A coluna ts_generation foi identificada como a marca temporal comum aos arquivos. Ela é armazenada como timestamp em milissegundos desde a época Unix e foi convertida para datetime para as análises.

A conversão permite comparar arquivos diferentes, estudar frequência de amostragem, alinhar sensores e investigar eventos de irrigação. Na EDA01, a análise temporal também mostrou que os arquivos cobrem períodos distintos, portanto não se deve assumir que todos os sensores possuem exatamente a mesma janela temporal.

8. EDA01 — Conclusão

A EDA01 mostrou que o dataset é suficientemente rico para sustentar o projeto, mas não deve ser usado de forma bruta. Há múltiplas frequências de amostragem, lacunas, sensores com comportamentos distintos e possíveis artefatos.

O principal resultado para a etapa seguinte foi a seleção de 2025 como foco da análise integrada, pois esse ano reúne, no mesmo período experimental, solo, ambiente, acionamento da válvula, volume de água e variáveis de resposta da planta.

9. EDA02 — Objetivo

A EDA02 deixou de apenas perguntar “como os dados são?” e passou a perguntar “o que acontece com a umidade do solo ao longo do tempo e como isso se relaciona com ambiente e irrigação?”.

Foram carregados environmental2025, soil2025, valve_controller2025 e water_meter2025. Os dados foram convertidos para datetime, ordenados temporalmente e associados às linhas de cultivo.

10. EDA02 — Integração temporal

A série integrada usa o solo como referência principal. As variáveis de válvula e medidor de água são associadas por line e proximidade temporal, enquanto as variáveis ambientais são associadas pelo instante de observação.

Para exploração, foi usada tolerância temporal de 5 minutos. Uma ressalva importante para a futura modelagem preditiva é evitar que uma observação futura seja usada para explicar uma observação passada; por isso, o alinhamento final do modelo deverá ser causal, preferencialmente usando observações anteriores (backward) e defasagens (lags).

11. EDA02 — Frequência de amostragem

A frequência do sensor de solo não é perfeitamente uniforme. Os intervalos medianos entre leituras foram aproximadamente:

- Linha 1: 6,65 min
- Linha 2: 9,69 min
- Linha 3: 6,65 min
- Linha 4: 5,02 min
- Linha 5: 8,29 min

Também existem intervalos extremos de milhares de minutos, que representam lacunas de aquisição e não a frequência normal do sensor. Por isso, a análise de variação temporal filtrou intervalos muito grandes.

12. EDA02 — Dinâmica da umidade

Foi calculada a variação entre leituras consecutivas dentro de cada linha:

$\Delta H = H(t+\Delta t) - H(t)$

O cálculo foi feito separadamente por linha, evitando comparar uma leitura de uma linha com a leitura seguinte de outra linha. Também foi calculada a taxa de variação em relação ao tempo.

O objetivo é distinguir dois fenômenos: redução de umidade enquanto o sistema não irriga e aumento de umidade após a aplicação de água. Entretanto, os resultados mostraram que a série contém saltos muito grandes que não podem ser interpretados automaticamente como fenômenos físicos.

13. EDA02 — Principais anomalias

A investigação dos 20 maiores saltos por linha revelou padrões altamente repetitivos. Existem sequências em que a umidade alterna entre níveis quase exatos, por exemplo aproximadamente 3,3 ↔ 35,3 na linha 1; 26,0 ↔ 45,8 na linha 2; 32,9 ↔ 48,1 na linha 3; 25,8 ↔ 54,7 na linha 4; e 30,0 ↔ 55,7 na linha 5.

Também aparecem saltos simultâneos entre diferentes linhas em 17/06/2025, aproximadamente entre 07:40 e 07:56.

Esse padrão é forte indício de artefato de aquisição, quantização, mudança de estado do sensor ou outra característica do sistema de geração dos dados. Não é seguro tratá-lo como “secagem natural” da planta.

14. EDA02 — Irrigação e resposta do solo

A variável valve_valve_state foi convertida em indicação de irrigação ativa. Foram identificados 628 registros ativos, agrupados em aproximadamente 100 eventos de irrigação.

Comparando ΔH entre momentos com e sem irrigação:

- Sem irrigação: média de $\Delta H \approx -0{,}0029$
- Com irrigação: média de $\Delta H \approx +0{,}8390$

O resultado é promissor porque a umidade tende a aumentar quando a válvula está ativa. Porém, isso é uma evidência exploratória, não uma prova causal: o efeito precisa ser estudado por evento, considerando duração da

abertura, volume aplicado e atraso entre irrigação e resposta do sensor.

15. EDA02 — Correlações

A matriz de Pearson foi usada como exploração inicial. Alguns resultados relevantes:

- soil_humidity × soil_temperature: r ≈ 0,429
- soil_humidity × air_temperature: r ≈ 0,375
- air_temperature × air_humidity: r ≈ –0,729
- soil_humidity × valve_state: r ≈ 0,044

A correlação muito baixa entre válvula e umidade não significa que irrigação não tenha efeito. A válvula é um evento relativamente esparso e a resposta do solo pode ocorrer depois do acionamento. Portanto, uma correlação contemporânea pode esconder uma relação temporal.

16. EDA02 — Comparação entre linhas

As linhas apresentam comportamentos diferentes, o que reforça a necessidade de modelagem por linha ou inclusão da linha como variável.

Médias de soil_moisture:

- L1: 24,25
- L2: 24,55
- L3: 21,54
- L4: 21,58
- L5: 27,95

Medianas:

- L1: 31,61
- L2: 32,52
- L3: 30,41
- L4: 27,14
- L5: 31,90

A diferença entre média e mediana, junto aos mínimos próximos de zero, mostra que a distribuição não é simples e que os eventos extremos influenciam bastante as estatísticas.

17. O que as duas EDAs permitem afirmar

1. O dataset possui informação suficiente para estudar irrigação autônoma. 2. 2025 é a parte mais interessante para o primeiro modelo porque conecta ambiente, solo, irrigação e resposta da planta. 3. A umidade do solo é uma variável central para a decisão de irrigação. 4. A irrigação apresenta indícios de resposta positiva na umidade do solo. 5. Ambiente e solo possuem relações mensuráveis, mas correlação não deve ser interpretada como causalidade. 6. Existem artefatos/anomalias importantes que precisam ser considerados antes do treinamento do modelo. 7. A dimensão temporal é essencial: o efeito da irrigação provavelmente possui atraso.

18. Hipótese de modelagem para a próxima etapa

A formulação mais coerente com o objetivo do projeto é prever a evolução da umidade, em vez de simplesmente classificar o instante atual como “regar” ou “não regar”.

Uma hipótese inicial é:

$\Delta H = f(T_amb, RH_amb, H_solo, irrigação, volume, tempo, histórico)$

Ou seja, o modelo tenta aprender como a umidade do solo tende a mudar em função das condições ambientais, do estado atual do solo e do histórico de irrigação.

A partir da previsão, um controlador pode manter a planta dentro de uma faixa:

$H_min \leq H(t) \leq H_max$

Isso combina Inteligência Computacional com uma regra de controle simples e interpretável.

19. Limitações e próximos passos

Antes do treinamento definitivo, recomenda-se:

- investigar os maiores saltos de umidade junto com valve_state e current_volume;
- descobrir exatamente a semântica de current_volume e transformá-la em volume/consumo por evento, se for uma leitura acumulada;
- usar alinhamento temporal causal;
- criar variáveis defasadas (lags) e janelas móveis;
- identificar e marcar artefatos sem apagar dados indiscriminadamente;
- separar treino, validação e teste respeitando a ordem temporal;
- comparar um baseline simples com modelos de Inteligência Computacional;
- avaliar o modelo não apenas por erro numérico, mas pela capacidade de manter a umidade dentro da faixa desejada.

20. Roteiro curto para apresentação

A apresentação pode seguir esta sequência:

1. “Começamos entendendo o dataset inteiro.” — EDA01. 2. “Encontramos 21 arquivos, distribuídos entre 2023, 2024 e 2025, com ambiente, solo, irrigação e resposta da planta.” 3. “Verificamos tipos, estatísticas, ausências e timestamps.” 4. “Também encontramos valores suspeitos, então não tratamos o dataset como perfeitamente limpo.” 5. “Escolhemos 2025 porque é o ano com a cadeia mais completa.” 6. “Na EDA02, integramos ambiente, solo, válvula e medidor de água.” 7. “A pergunta passou a ser: como a umidade muda e qual é o efeito da irrigação?” 8. “Encontramos cerca de 100 eventos de irrigação e uma variação média positiva de umidade quando a válvula está ativa.” 9. “Mas encontramos também saltos artificiais e repetitivos na umidade; portanto, não podemos chamar esses saltos de secagem ou irrigação sem validação.” 10. “O próximo passo é usar a dinâmica temporal para prever a evolução da umidade e então tomar a decisão automática de irrigar.”

21. Referência do dataset

Belli, Laura; Davoli, Luca; Oddi, Giulia; Preite, Luca; Galaverni, Martina; Ganino, Tommaso; Ferrari, Gianluigi (2024). “IoT-based Dataset of a Tomato Cultivation Under Different Irrigation Regimes”. Mendeley Data, V2. DOI: 10.17632/35wh56287y.2.

Observação metodológica

Os resultados acima foram consolidados a partir dos outputs das EDA01/EDA02 e das análises discutidas durante o desenvolvimento. Interpretações sobre causalidade, física do solo ou semântica exata dos sensores são apresentadas como hipóteses quando não foram diretamente demonstradas pelo dataset.