Relatório Consolidado da EDA
Dataset de Cultivo de Tomate

Seções 01–11

Relatório consolidado dos principais resultados, interpretações e limitações identificados na análise exploratória dos dados (EDA).

Visão geral antes das seções

A EDA está começando a revelar uma estrutura bastante interessante para o projeto.

O dataset de 2025 possui uma cadeia temporal que permite relacionar:

```
condições ambientais → estado da água no solo → irrigação → resposta do solo
```

Além disso, existem dados de resposta da própria planta, como temperatura foliar, crescimento do caule e frutos, embora ainda não tenham sido incorporados à análise principal.

O ponto mais importante até aqui é que a umidade do solo apresenta diferenças muito grandes entre sensores, enquanto as correlações ambientais instantâneas com sua variação são praticamente nulas. Já a análise dos eventos de irrigação mostra uma resposta claramente heterogênea entre linhas e sensores.

Isso sugere que o problema provavelmente não será bem representado por uma regra extremamente simples como:

```
"temperatura alta → irrigar".
```

A dinâmica parece depender muito mais do estado atual do solo, posição/sensor, histórico de irrigação e evolução temporal.

01. Levantamento e caracterização inicial dos dados

Objetivo

A primeira etapa teve como finalidade entender o que existe no dataset antes de decidir como modelá-lo: arquivos, quantidade de registros, colunas, variáveis temporais, identificadores e estatísticas iniciais.

Resultado

O levantamento identificou dados dos anos 2023, 2024 e 2025, com diferentes níveis de instrumentação. O inventário inclui, entre outros, environmental, soil, valve_controller / water_valve, water_meter, water_potential, pressure, fruit, leaf_temperature, stem e indicators.

Resultado
A estrutura mais rica para nosso problema aparece em 2025, especialmente nos conjuntos de solo, ambiente, válvula, hidrômetro e variáveis de crescimento da planta.

Resultado
O inventário bruto registra, por exemplo, 193.066 registros em soil2025, 102.014 em valve_controller2025, 143.470 em water_meter2025, 261.013 em leaf_temperature2025 e 201.899 em fruit2025.

Características físicas relevantes
A documentação de soil2025 mostrou que existem 10 sensores Milesight EM500 SMTC, dois por linha, sendo um instalado a 15 cm e outro a 30 cm. Cada sensor fornece umidade do solo, temperatura do solo e condutividade elétrica.

Análise
Essa estrutura é particularmente adequada ao nosso problema porque não temos simplesmente uma série de “umidade do solo”: temos múltiplos sensores espacialmente distribuídos, em diferentes profundidades, acompanhando o mesmo sistema agrícola.

Limitações
Ainda não temos, no contexto disponível, a correspondência documentada entre cada hash generated_by e 15 cm/30 cm. Portanto, não devemos atribuir arbitrariamente uma profundidade aos hashes.

02. Verificação temporal

Objetivo
Verificar período coberto, frequência de amostragem, regularidade, lacunas e diferenças entre sensores.

Resultado principal
A série de solo apresenta frequência extremamente regular:
linha 1 ≈601,36 s;
linha 2 ≈601,36 s;
linha 3 ≈601,37 s;
linha 4 ≈601,37 s;
linha 5 ≈601,36 s.

Isso corresponde a aproximadamente 10 minutos entre leituras.

Resultado
A válvula apresenta mediana aproximadamente 600 s por leitura. O ambiente também apresenta mediana de aproximadamente 601,62 s.

Lacunas
Embora a frequência normal seja de aproximadamente 10 minutos, existem intervalos enormes. Alguns sensores de solo apresentam intervalos máximos superiores a 710.000 segundos, isto é, mais de oito dias.

Análise
O dataset é regularmente amostrado quando está funcionando, mas possui períodos de ausência de dados. Isso é muito diferente de dizer que os dados são uniformemente distribuídos no tempo.

Implicação
Não podemos assumir que cada registro consecutivo representa exatamente 10 minutos. Precisaremos considerar Δt explicitamente para taxas de secagem, previsão de umidade e resposta à irrigação. Ou, ainda, cortar as amostras em subespaços em que podemos confirmar que o intervalo foi de 10 minutos e analisar dentro desses grupos o comportamento, isolando qualquer interação maior do que isso.

03. Integração da série temporal

Objetivo
Construir uma série única relacionando solo, ambiente, válvula e hidrômetro sem destruir a identidade dos sensores.

Decisão conceitual
Os generated_by dos diferentes datasets não são iguais. Portanto, não seria correto fazer line + generated_by + datetime para unir literalmente todos os datasets.

Estrutura adotada
O solo foi utilizado como série-base, preservando line, generated_by, datetime, soil_humidity e soil_temperature. Válvula e hidrômetro foram alinhados por line + datetime; ambiente foi alinhado temporalmente por datetime.

Preservação de metadados
Os identificadores dos outros dispositivos foram preservados como valve_generated_by, water_generated_by e environmental_generated_by.

Alinhamento
Para a EDA foi utilizado merge_asof com correspondência temporal mais próxima e tolerância de 5 minutos.

Análise
A escolha preserva simultaneamente a identidade física do sensor de solo e a relação temporal com os demais dispositivos.

Limitação
Esse alinhamento de ±5 minutos é adequado para exploração, mas não deve ser automaticamente utilizado no treinamento final. Para previsão causal/temporal, será provavelmente mais adequado usar alinhamento causal/backward. Contudo, esse formato foi mantido por já estar implementado e outras alterações serem prioritárias.

04. Qualidade dos dados relevantes

Objetivo
Avaliar valores ausentes, zeros, quantidade de dados válidos e qualidade das variáveis relevantes para a irrigação.

Solo
soil_humidity e soil_temperature apresentaram 0% de valores ausentes na série integrada considerada.

Variáveis auxiliares
Os dados integrados de ambiente, válvula e hidrômetro apresentam valores ausentes decorrentes principalmente do alinhamento temporal. O ambiente apresentou aproximadamente 15,3% de ausência.

Valores estranhos
Algumas variáveis do dataset bruto possuem valores potencialmente estranhos: umidade do solo 2024 chegando a 655,35; condutividade chegando a 65.535; pressão com grande quantidade de zeros; temperatura foliar com valores 0.

Análise
Esses valores não devem ser automaticamente excluídos. Podem representar codificação do sensor, valores sentinela, falhas, saturação ou escalas específicas.

Conclusão
No caso de 2025, a umidade do solo é particularmente mais comportada, com valores observados aproximadamente entre 0 e 58,76.

05. Estatísticas da umidade do solo

Resultado geral
Média 23,78;
mediana 30,47;
Q1 2,48;
Q3 36,09;
máximo 58,76.

Análise

A enorme diferença entre média e mediana indica uma distribuição com muitos valores baixos, incluindo valores próximos de zero.

Diferenças entre sensores

Linha 1: ≈22,7% e ≈25,7%.
Linha 2: ≈20,8% e ≈28,3%
Linha 3: ≈21,6% e ≈21,5% (basicamente inexistente, menos de 0,6 pontos percentuais de diferença, sem arredondamento).
Linha 4: ≈17,9% e ≈25,5%.
Linha 5: sensor 0da... ≈37,9% e sensor 19b... ≈22–23%.

Análise

O sensor 0da... da linha 5 possui média em torno de 37,9%, mediana ≈37,25% e apenas 10.607 registros, enquanto o outro sensor possui quase 20 mil.

Conclusão

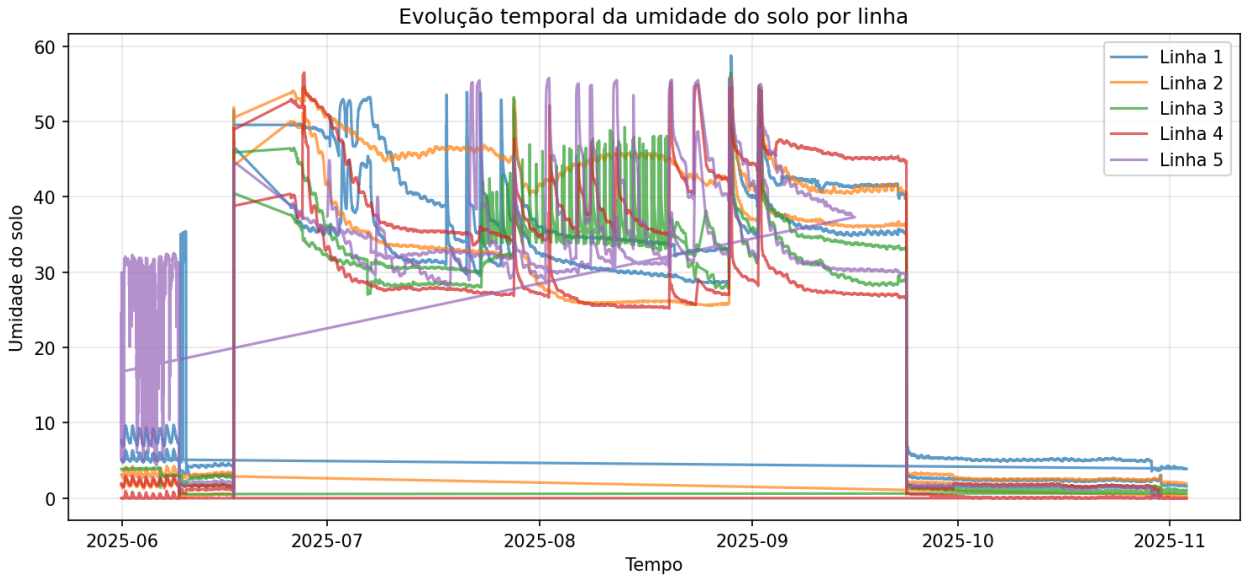
Não podemos simplesmente fazer a umidade média da linha e tratá-la como “a umidade da linha”. Há diferenças substanciais entre sensores.

Hipóteses

Existem pelo menos três hipóteses: profundidades diferentes; condições físicas diferentes; comportamento/posicionamento dos sensores. A hipótese da profundidade é especialmente relevante por sabermos que há diferença em relação a isso, mas ainda não podemos afirmar qual sensor é qual.

Cuidado

soil_humidity está documentada como %RH do sensor, portanto não devemos simplesmente chamá-la de “umidade volumétrica do solo (%)”.



06. Dinâmica temporal da umidade

Pergunta

Como a água está mudando no solo ao longo do tempo?

Frequência

A mediana dos intervalos continua próxima de 10 minutos para praticamente todos os sensores.

Variação

A maior parte das variações consecutivas é pequena, porém existem eventos de variação muito maiores.

Exemplo

No sensor 19b... da linha 5:
mediana de Δumidade = 0; 99% das variações abaixo de ≈4,66;
99,9% abaixo de ≈18,49;
máximo = 43,59.

Comparação

No sensor 0da... da mesma linha,
99% das variações estão abaixo de ≈0,54 e
o máximo é ≈14,14.

Lacunas

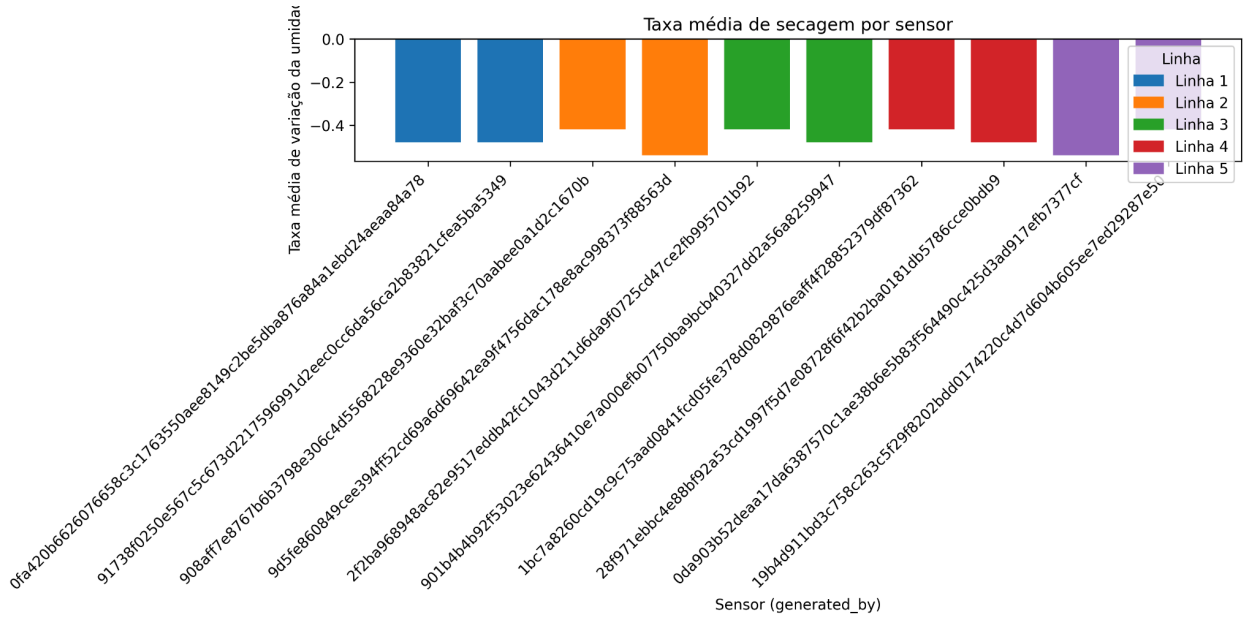
Para análise da taxa de variação foram considerados intervalos de aproximadamente $1 < \Delta t \leq 30$ minutos.

Análise

A dinâmica normal do solo é relativamente lenta, mas existem mudanças abruptas que merecem investigação. Podem estar associadas a irrigação, redistribuição da água, profundidade ou sensor.

Cuidado

Ainda não podemos chamar todo Δumidade negativo de “secagem natural”.



07. Identificação dos eventos de irrigação

Objetivo

Transformar a série da válvula em eventos físicos de irrigação.

Resultado

A válvula apresenta amostragem próxima de 10 minutos, assim como o solo.

Primeira identificação

A primeira lógica identificou 97 possíveis eventos:

linha 1 = 8;

linha 2 = 7;

linha 3 = 74;

linha 4 = 8;

linha 5 não apareceu nessa etapa.

Análise
A irrigação aparentemente não está distribuída uniformemente entre as linhas. A linha 3 concentra grande parte dos eventos identificados.

Hipóteses
Isso pode ter relação com características da linha, condição hídrica, configuração do sistema, sensores, período de funcionamento ou cobertura temporal.

Limitação
A abertura da válvula não fornece automaticamente a quantidade de água aplicada. Precisamos entender a semântica de current_volume.

Observação metodológica
Na Seção 08, com lógica revisada de identificação/transição, chegaram-se a 100 eventos físicos. A definição de evento mudou entre as etapas; para o relatório final, precisamos documentar qual definição será oficial.

08. Resposta do solo à irrigação

Pergunta
O solo realmente responde à irrigação?

Resultado
A resposta exploratória é sim, mas depende fortemente do sensor/linha.

Variação
Fora da irrigação: média Δumidade ≈−0,0036. Durante irrigação: ≈+1,038.

Resposta por sensor
Linha 1: 0fa... ≈+7,65 e 917... ≈+8,53. Linha 3: 2f2... ≈−0,013 e 901... ≈+7,18. Linha 4: 1bc... ≈+6,56 e 28f... ≈+6,41.

Análise
Na mesma linha existem sensores com respostas drasticamente diferentes. O exemplo mais impressionante é a linha 3, com um sensor praticamente sem resposta média e outro com aumento médio de ≈7,18.

Hipótese
Isso reforça a hipótese de que os dois sensores observam condições diferentes no perfil do solo — potencialmente relacionadas às profundidades. Não podemos afirmar qual é 15 cm e qual é 30 cm sem a correspondência documentada.

Resposta após início
+10 min ≈+0,99; +20 ≈+2,90; +30 ≈+3,76; +60 ≈+3,49; +120 ≈+2,80.

Resposta após término

+10 min ≈−0,10; +20 ≈−0,29; +30 ≈−0,36; +60 ≈−1,00; +120 ≈−1,63.

Duração

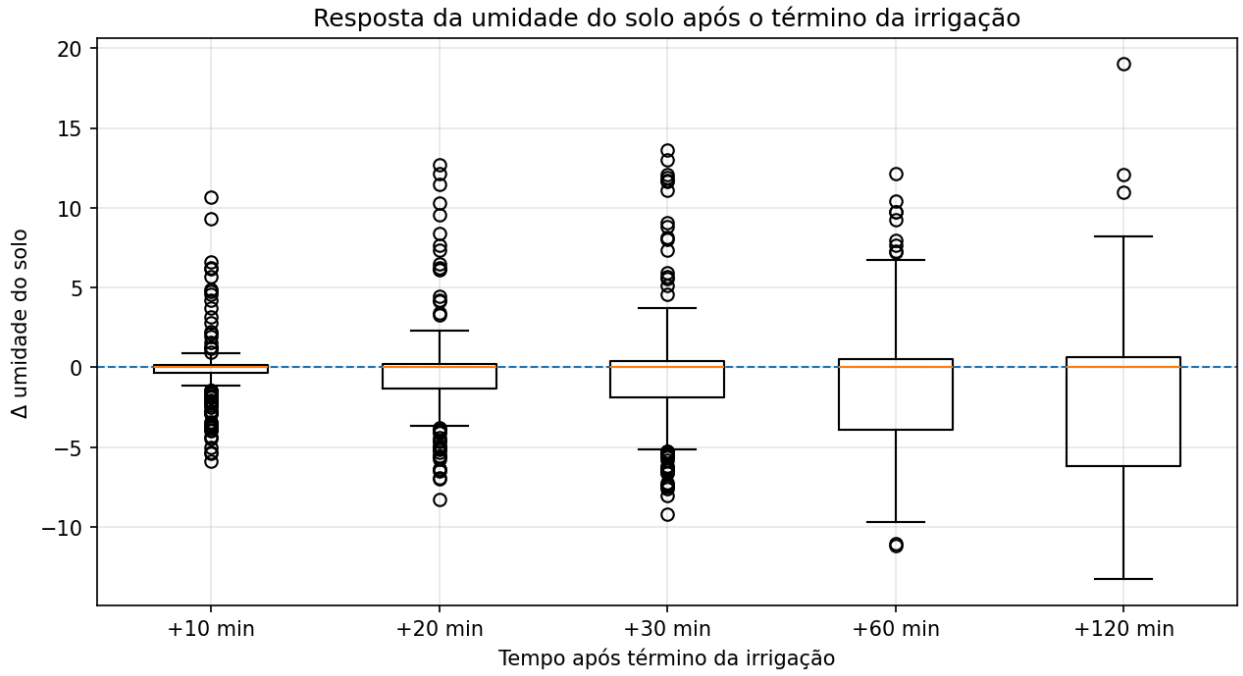
Média ≈32,16 min; mediana ≈30,07 min; mínimo ≈3,27 min; máximo ≈157,42 min.

Conclusão

A irrigação está associada a aumentos da umidade; o aumento pode persistir após o início; depois do encerramento a umidade tende a cair novamente; a magnitude da resposta varia muito entre sensores.

Cuidado

Ainda é análise exploratória. Não podemos dizer que a irrigação causou determinada variação para cada observação individual.



09. Padrão diurno da umidade

Pergunta

Existe um ciclo diário perceptível na umidade do solo?

Resultado

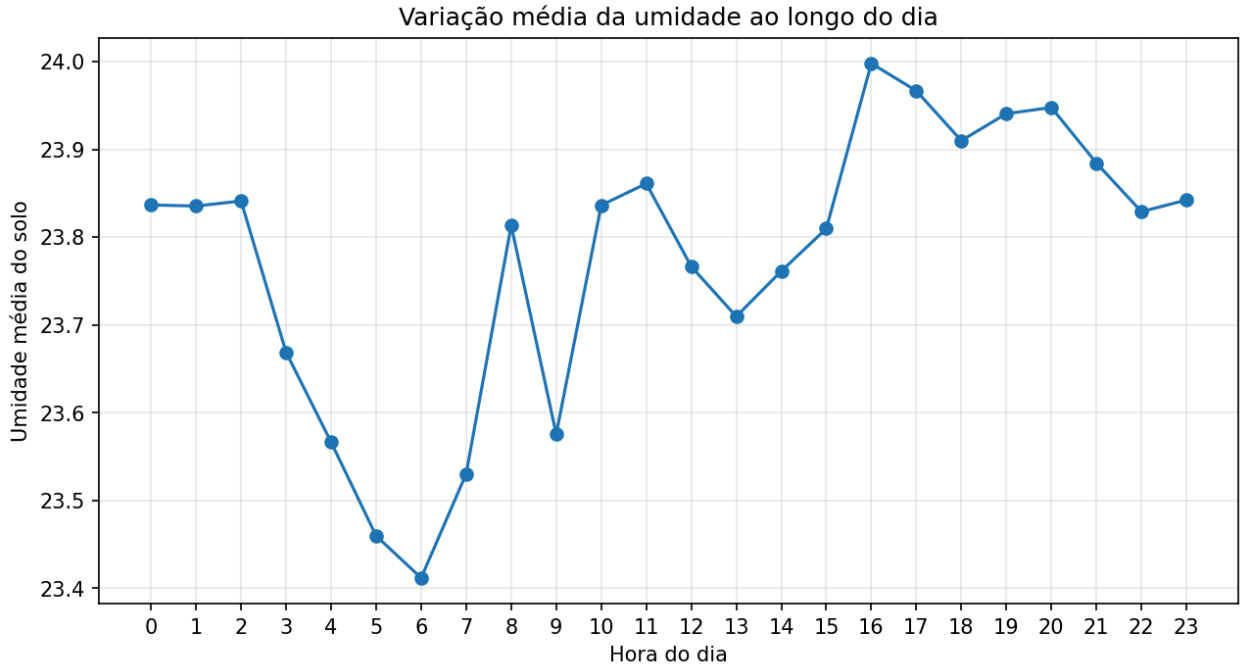
A média global varia aproximadamente de 23,41% às 6h a 24,00% às 16h, amplitude de ≈0,59 ponto percentual.

Mediana
Permanece praticamente constante, em torno de 30,3–30,6.

Análise
Não há um ciclo diurno global forte. A grande variabilidade entre sensores continua presente durante todas as horas.

Interpretação
Isso enfraquece a hipótese de que a hora do dia sozinha explique a umidade do solo.

Cuidado
Horário ainda pode funcionar como variável contextual, representando indiretamente radiação, temperatura, evapotranspiração e rotina de irrigação.



[ESPAÇO RESERVADO PARA IMAGEM — 09 — Padrão diurno da umidade]

Inserir 09_padrao_diurno_umidade.png.

10. Influência das variáveis ambientais

Pergunta
Temperatura e umidade do ar explicam a variação da umidade do solo?

Resultado

Temperatura ambiente × Δumidade: r=−0,008618. Umidade ambiente × Δumidade: r=+0,008748.

Por sensor

O resultado se mantém em todos os sensores; a maior magnitude observada foi aproximadamente |r|≈0,037.

Conclusão

Não existe evidência de relação linear instantânea relevante entre essas variáveis e a mudança imediata da umidade.

Interpretação

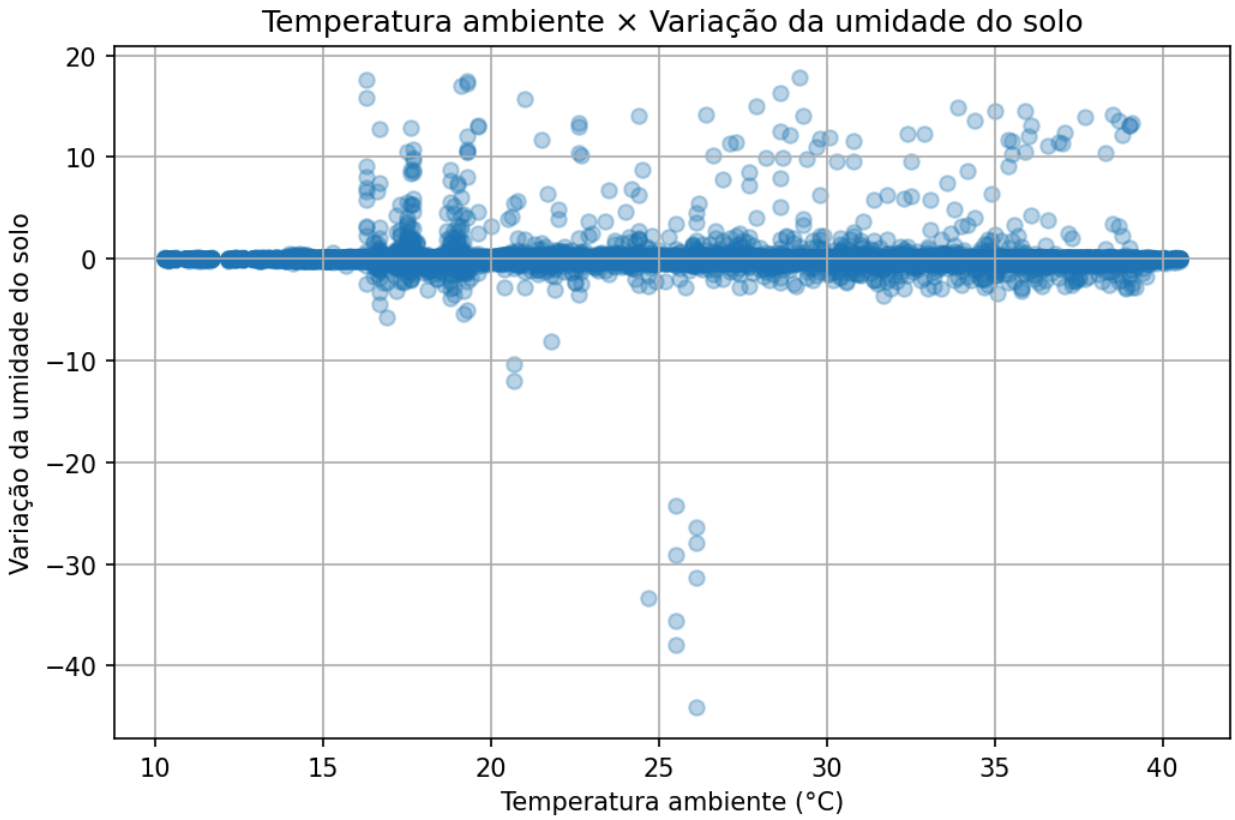
Isso não significa que temperatura e umidade ambiente não influenciem a necessidade de irrigação. A relação pode ser defasada: temperatura → evapotranspiração → perda acumulada → umidade do solo.

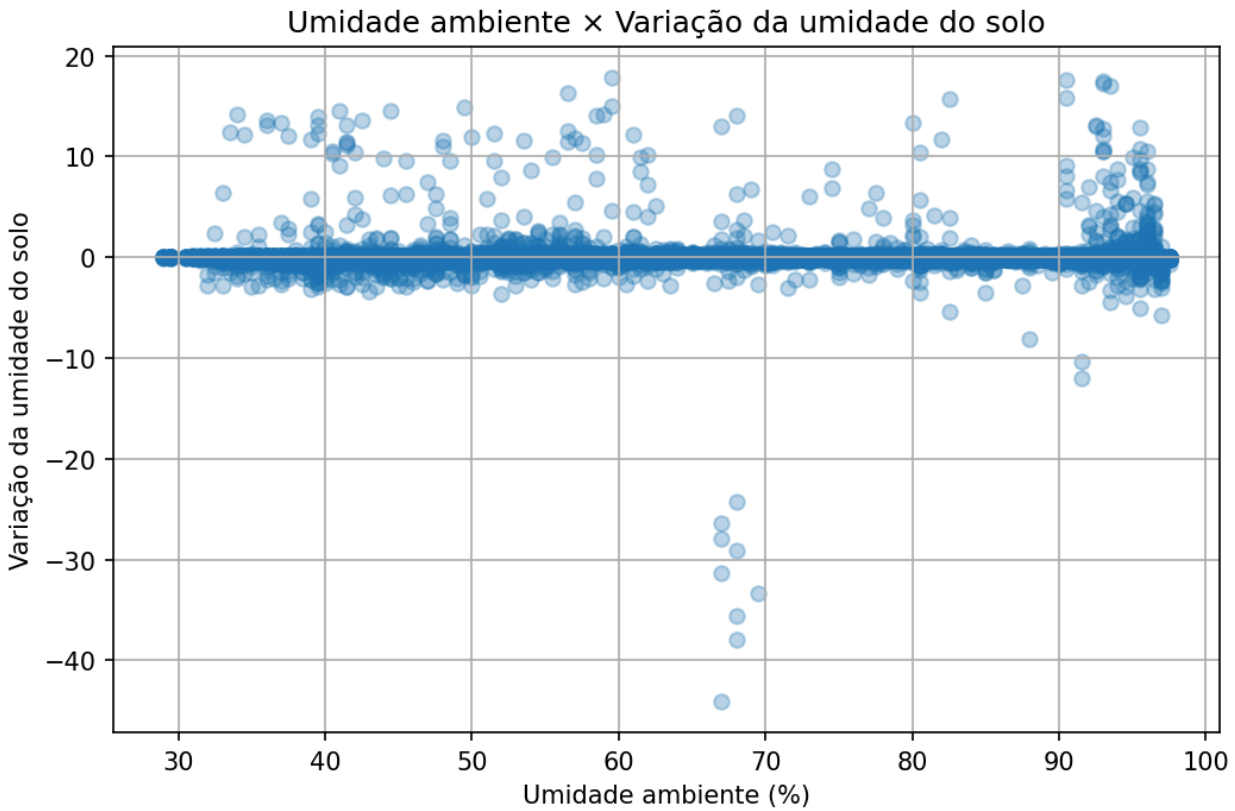
Confundimento

A irrigação também pode mascarar a relação: temperatura ↑ → necessidade de água ↑ → irrigação ↑ → umidade ↑.

Conclusão formal

A correlação instantânea não identificou associação linear relevante entre temperatura/umidade ambiente e a variação imediata da umidade. Isso não descarta efeitos defasados, não lineares e mediados pela irrigação.


Temperatura ambiente × Variação da umidade do solo
Variação da umidade do solo
Temperatura ambiente (°C)
20
10
0
−10
−20
−30
−40
10
15
20
25
30
35
40


Umidade ambiente × Variação da umidade do solo
Variação da umidade do solo
Umidade ambiente (%)
20
10
0
−10
−20
−30
−40
30
40
50
60
70
80
90
100

[ESPAÇO RESERVADO PARA IMAGEM — 10 — Influência ambiental]

Inserir um dos gráficos de dispersão da Seção 10.

11. Correlação entre as variáveis e a umidade do solo

Pergunta

Quais variáveis apresentam associação com o nível de umidade do solo?

Resultado

CO_2 ambiente −0,533; temperatura do solo +0,429; temperatura ambiente +0,375; umidade ambiente +0,157; volume de água −0,053; estado da válvula +0,044; pressão ambiente −0,042.

Análise

CO_2 apresenta a maior correlação em magnitude; depois vêm temperatura do solo e temperatura ambiente.

CO_2

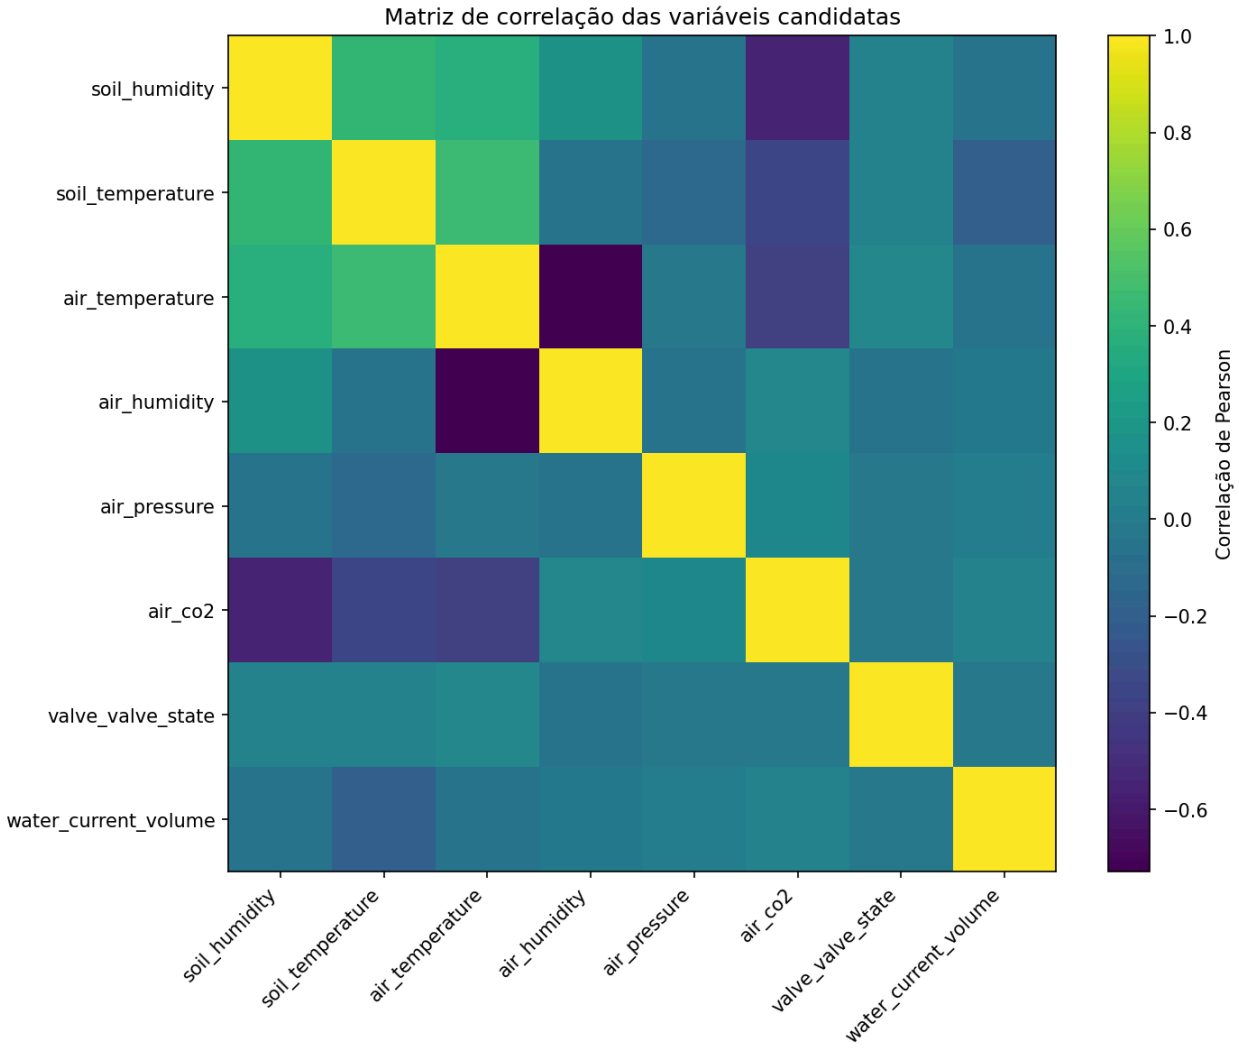
A correlação −0,533 não significa que CO_2 esteja causando secagem ou umidade. Pode funcionar como marcador indireto de horário, atividade ambiental, condições de cultivo ou ventilação.

Temperatura do solo

A correlação ≈+0,429 indica associação entre maior temperatura do solo e maior umidade no conjunto de dados. Ainda assim, correlação não implica causalidade.

Temperatura ambiente

Também apresenta associação moderada, r≈+0,375, mostrando que pode conter informação sobre o estado do sistema, apesar de não explicar a variação instantânea na Seção 10.



Conclusão

CO_2 apresentou associação estatística relativamente forte com o nível de umidade observado e merece investigação como variável potencialmente informativa; isso não significa que seja causal ou necessariamente necessária ao controlador.

O que as 11 seções contam juntas?

1. Temos dados temporais suficientemente regulares

Os sensores operam aproximadamente a cada 10 minutos, embora existam lacunas importantes.

2. O solo não é homogêneo

Os sensores apresentam comportamentos e níveis médios bastante diferentes.

3. Preservar sensor e linha é essencial

Não podemos simplesmente agregar tudo em uma única “umidade do solo”.

4. A irrigação realmente produz resposta observável
Quando a válvula abre, alguns sensores apresentam aumentos expressivos de umidade.

5. A resposta não é igual em todos os sensores
Alguns respondem muito, outros pouco.

6. Depois que a irrigação termina, a umidade tende a cair
Existe uma dinâmica temporal clara.

7. O horário sozinho explica pouco
O padrão médio por hora é fraco.

8. A correlação ambiental instantânea também explica pouco
Temperatura e umidade ambiente praticamente não explicam o Δumidade imediato.

9. Algumas variáveis possuem informação sobre o estado do solo
Temperatura do solo, temperatura ambiente e CO_2 apresentam associações relevantes com o nível de umidade.

O que isso muda para o modelo?
A EDA está dando argumentos contra um modelo simplista do tipo:

```
SE umidade < X → ENTÃO liga válvula
```

Não necessariamente porque essa regra não funcionaria, mas porque o dataset contém uma dinâmica muito mais rica.

```
ΔH = f(H_solo, T_solo, T_amb, RH_amb, irrigação, histórico, tempo)
```

Ou, ainda melhor, tentar prever:

```
H(t+Δt)
```

A decisão de ligar/desligar a bomba poderia então ficar acima do modelo, como uma camada de controle.

Isso casa muito bem com o objetivo do projeto: o sistema não deve apenas “prever alguma coisa”, mas manter automaticamente a planta dentro de uma condição hídrica adequada.

Principais achados da EDA até a Seção 11

Achado	Evidência
Sensores operam ~10 min	Seções 02/06
Existem lacunas temporais grandes	Seções 02/06
Há forte heterogeneidade entre sensores	Seções 05/09/12
Irrigação produz resposta mensurável	Seção 08
Resposta depende do sensor	Seção 08
Umidade tende a cair após irrigação	Seção 08

Padrão horário global é fraco	Seção 09
Correlação ambiental instantânea é quase nula	Seção 10
Algumas variáveis se associam ao nível de umidade	Seção 11
CO_2 possui correlação relativamente forte, mas não causalmente interpretável	Seção 11
Temperatura do solo possui associação relevante com umidade	Seção 11
generated_by deve ser preservado	Seções 02–05
Profundidade 15/30 cm ainda não pode ser atribuída aos hashes	Seções 01/05/08

Próximas questões relevantes

1. Descobrir a identidade física dos sensores

Precisamos resolver:

```
Linha X
├── generated_by A → 15 cm?
└── generated_by B → 30 cm?
```

Isso pode mudar bastante a interpretação das diferenças encontradas.

2. Transformar irrigação em quantidade de água

Precisamos entender current_volume. Se for acumulativo, podemos transformar volume antes/depois de um evento em volume efetivamente irrigado.

```
V_evento = V_fim − V_início
```

Isso seria muito mais útil para o modelo do que apenas valve_state.

3. Começar a pensar na variável-alvo

Depois de 11 seções, a pergunta deixa de ser simplesmente “O que existe no dataset?” e passa a ser “O que exatamente queremos que nosso modelo aprenda a prever?”

Com o que vimos até agora, uma candidata particularmente interessante é $H(t+\Delta t)$, isto é, prever a umidade futura do solo a partir do estado atual, ambiente, histórico e ações de irrigação.

Observação metodológica

Os resultados das seções posteriores não foram usados para “corrigir” retroativamente as anteriores. Onde houve mudança de metodologia — especialmente a identificação de eventos, que passou de 97 na Seção 07 para 100 na lógica revisada da Seção 08 — a diferença foi mantida explícita. Os resultados devem ser entendidos dentro da definição metodológica de cada seção.